AUTOREN: Saleh Shaaban, Samir Panah, Alexander Gaiduk,
Mohamad Said, Mohamad Hussien , Bahoz Shekho

BETREUER: *Thorben Schomacker*

NYC-Housing Price Prediction

Bahoz Shekho / SoSe26_PRO_DS · GitLab
UNIVERSITÄT: HAW HAMBURG
LERNSTOF: Machine Intelligence & Data Science
Sommer semester 2026

Motivation & Forschungsfrage

NYC-Immobilienpreise folgen **keinem linearen Muster**: Lage, Fläche und Gebäudetyp wirken zusammen und oft unterschiedlich je nach Ortschaft.
→ Lineare Modelle reichen oft nicht.
→ **Welches ML-Modell liefert die beste Vorhersage?**

Datensatz

Quelle: NYC Housing Database
Umfang: 34.439 Rohdatensätze → 31.690 nach Bereinigung
Merkmale: Standort, Fläche, Baujahr, Gebäudetyp u.a.
19 Spalten → 124 Features nach One-Hot Encoding
Zielvariable: sale_price (Verkaufspreis in USD)
Preisspanne: 100.000 – 7.000.000 USD | Median: 840.000 USD
Verteilung: rechtsschief → nicht-lineare Modelle sinnvoll
Bereinigung:
· Fehlende Koordinaten entfernt
· Ausreißer bei Preis & Fläche (1.–99. Perzentil)

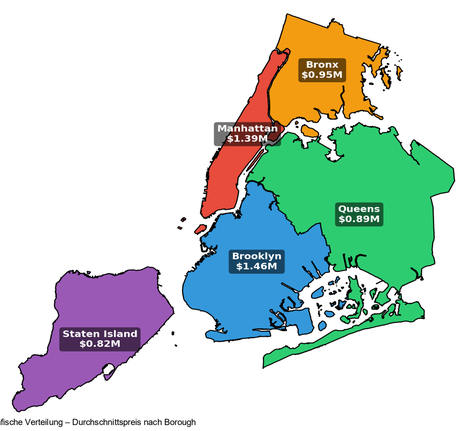


Abb. 1: Geografische Verteilung – Durchschnittspreis nach Borough

Methodik

1. **Datenbereinigung (Phase 1):** Fehlende Werte · Ausreißerfilter · EDA
2. **Feature Engineering (Phase 2):** Neue Features (Größe, Alter) · One-Hot Encoding → 124 Features price_per_square_meter bewusst nicht in X (Data Leakage vermieden)
3. **Modelltraining & Tuning (Phase 3–4):** Lineare Regression | Random Forest | XGBoost Hyperparameter-Optimierung per Grid Search auf Validierungsset
4. **Evaluation (Phase 5):** Modellvergleich auf Validierung · finales Testset (10 %) für Endbewertung

Metriken: R^2 (Erklärungsgrad) · MAE (Ø-Fehler in USD) · RMSE (große Fehler stärker gewichtet)

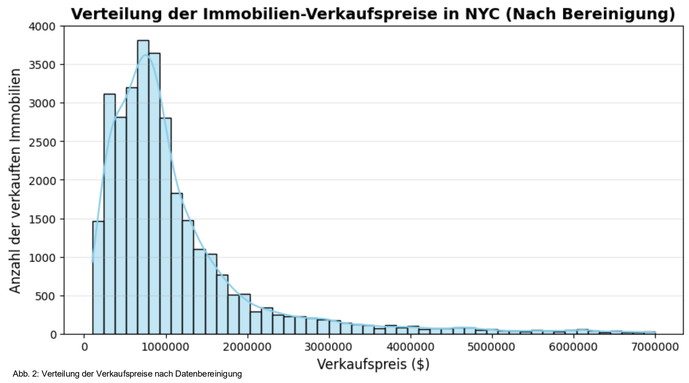


Abb. 2: Verteilung der Verkaufspreise nach Datenbereinigung

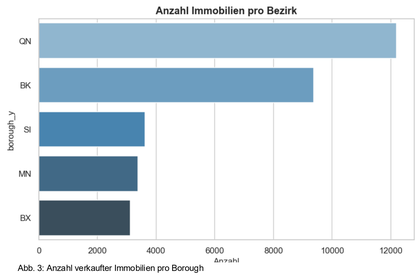


Abb. 3: Anzahl verkaufter Immobilien pro Borough

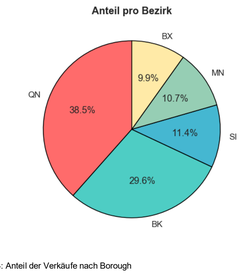


Abb. 4: Anteil der Verkäufe nach Borough

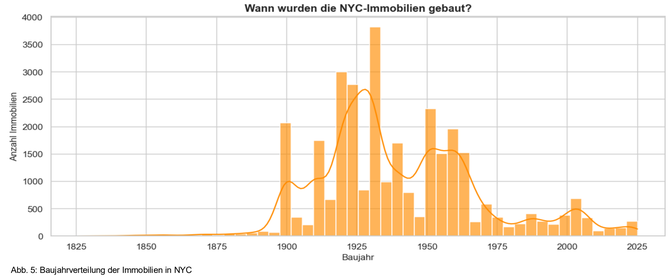


Abb. 5: Baujahrverteilung der Immobilien in NYC

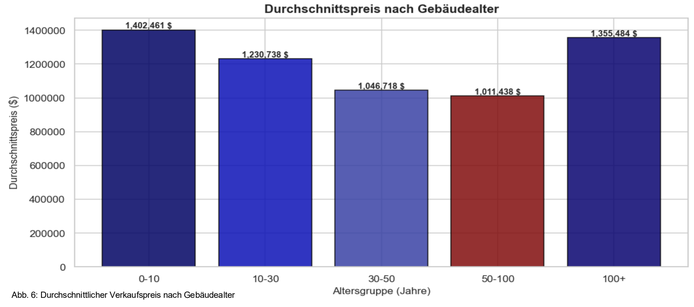


Abb. 6: Durchschnittlicher Verkaufspreis nach Gebäudealter

Modellierung (drei Ansätze)

Lineare Regression	Einfaches Modell: Preis = lineare Kombination der Features. Kein Tuning — dient als Vergleichsbasis.
Random Forest	Viele Entscheidungsbäume (Ensemble); erfasst nicht-lineare Muster. Grid Search (Validierung): n_estimators × max_depth → Beste Werte: 150 Bäume, max_depth = 20
XGBoost	Gradient Boosting: Bäume bauen nacheinander auf Fehlern der Vorgänger auf. Grid Search: learning_rate × max_depth (150 Estimators) → Beste Werte: lr = 0,10, max_depth = 9

Gemeinsam: 124 Features · Split 80/10/10 · Auswahl nach niedrigstem MAE

Modellvergleich (Validierung)

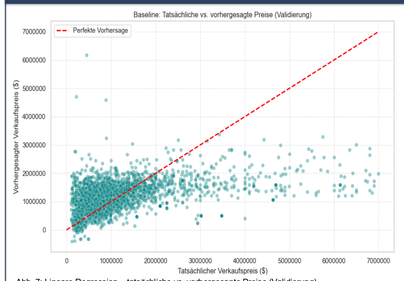


Abb. 7: Lineare Regression – tatsächliche vs. vorhergesagte Preise (Validierung)

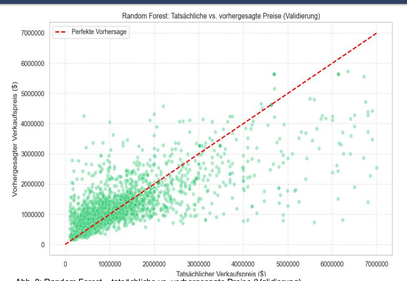


Abb. 8: Random Forest – tatsächliche vs. vorhergesagte Preise (Validierung)

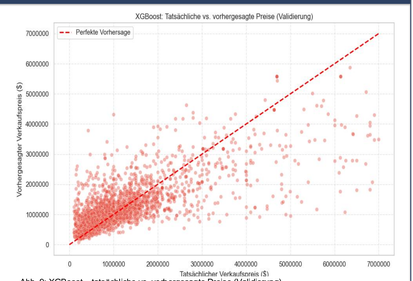


Abb. 9: XGBoost – tatsächliche vs. vorhergesagte Preise (Validierung)

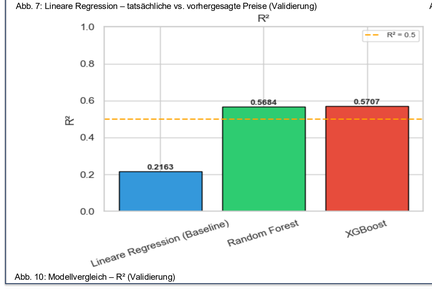


Abb. 10: Modellvergleich – R^2 (Validierung)

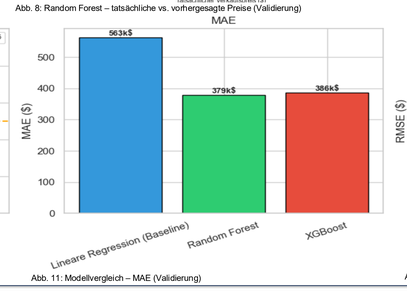


Abb. 11: Modellvergleich – MAE (Validierung)

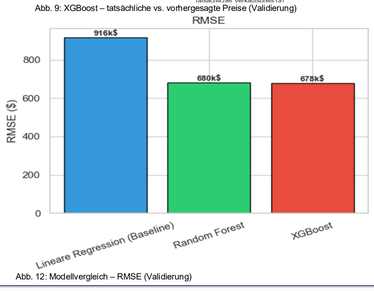


Abb. 12: Modellvergleich – RMSE (Validierung)

Finale Evaluation (XGBoost)

- Metriken auf Test nahe an Validierung — kein starkes Overfitting
- Modell generalisiert gut auf neue Daten
- Test leicht besser als Validierung
- stabile Prognose

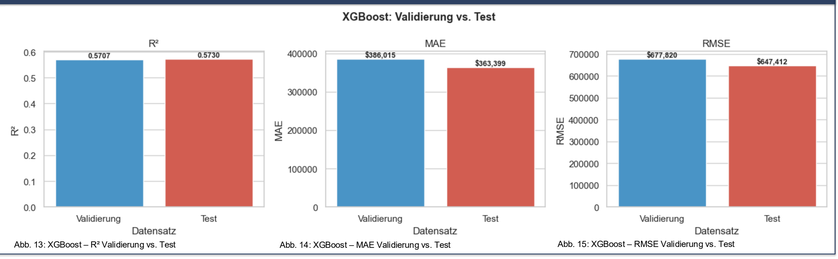


Abb. 13: XGBoost – R^2 Validierung vs. Test

Abb. 14: XGBoost – MAE Validierung vs. Test

Abb. 15: XGBoost – RMSE Validierung vs. Test

Limitationen

- ~43 % der Preisvarianz bleiben unerklärt
- Fehlende Faktoren: Renovierung, U-Bahn-Nähe, Schulqualität, Mikrolage
- Luxus- und Sonderobjekte werden eher unterschätzt
- MAE ~363.000 $ — für günstigere Objekte relativ hoch
- Modell gilt für NYC-Verkaufsdaten; Übertragung auf andere Städte begrenzt

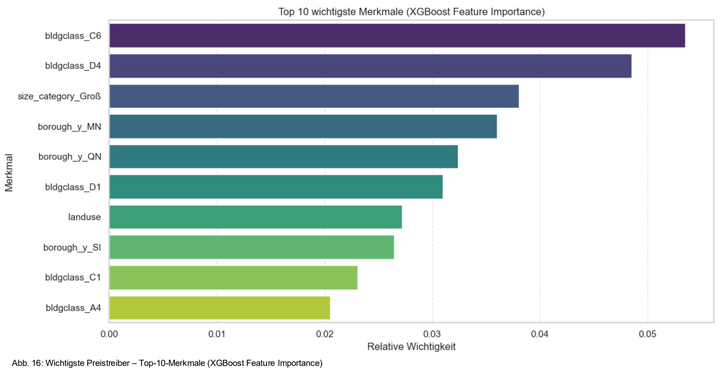


Abb. 16: Wichtigste Preistreiber – Top-10-Merkmale (XGBoost Feature Importance)

Fazit

- XGBoost sagt NYC-Immobilienpreise am genauesten voraus ($R^2 \approx 0{,}57$)
- Deutlicher Sprung gegenüber linearer Regression ($R^2 \approx 0{,}22$)
- Generalisierung gut: Test-Metriken ≈ Validierung
- Wichtigste Treiber: Standort (Borough), Wohnfläche, Gebäudetyp
- Nicht-lineare Ensemble-Modelle sind für diesen Datensatz geeignet