Expected Goals (xG/xGoal) Metrik für Fußballspiele deutscher Wettbewerbe

Robin Pankonin / Lucas Hilbig / Tom Küppers

Einleitung & Forschungsfrage

Im Rahmen des Projekts hatten wir die Möglichkeit, mit offiziellen Datensätzen der DFL zu arbeiten. Nach einer ersten Erkundung und Analyse der Daten sind wir auf folgende **Forschungsfrage** gestoßen:

„Kann man mit den uns zur Verfügung gestellten Datensätzen ein Modell trainieren, welches einen xGoal-Wert für einen Schuss berechnet – und welche Parameter beeinflussen die Wertigkeit einer Torchance?“

Was ist xGoal?

Der xGoal-Wert (Expected Goals, kurz xG) ist eine statistische Kennzahl im Fußball, die die Qualität einer Torchance bewertet. Er gibt die mathematische Wahrscheinlichkeit an, mit der ein bestimmter Schuss zu einem Tor führt.

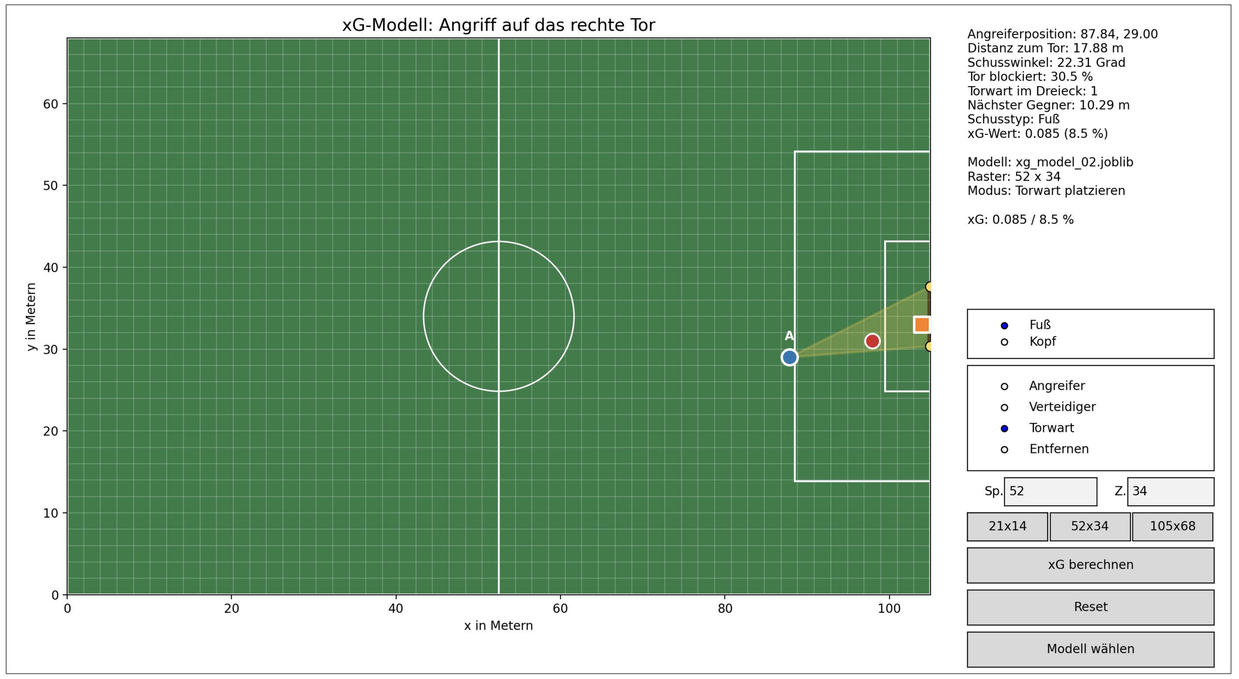
Welche Daten haben wir genutzt?

- **Rohe Eventdaten** (Koordinaten, Schussattribute; Tor/kein-Tor-Label)
- **Rohe Positionsdaten** (Tracking 25 Hz: Position & Tempo aller Spieler und Ball)
- **Spielspezifische Metadaten** (Wettbewerbe, Vereine, Spieler, Stadien, Aufstellungen)

Datenumfang – alle gescrapten Datensätze:

- **3.094 Schüsse** aus 115 Spielen · 38 Teams
- davon **355 Tore (11,5 %)** · 2.739 Nicht-Tore (88,5 %)
- **Schusstyp:** 2.635 Fußschüsse (85,2 %) · 459 Kopfbälle (14,8 %)
- **Ø pro Spiel:** 26,9 Schüsse · 3,1 Tore
- **Train/Test (80/20):** 2.475 / 618 Schüsse

(Auffällig: Kopf- und Fußschüsse mit identischer Torquote (11,5 %) – untypisch, evtl. wegen der kompakten Datenbasis (115 Spiele).)



Ergebnisse

Model 01 — Basis

Features: Distanz zum Tor · Schusswinkel · Anzahl Gegner im Sichtdreieck

Ergebnis: ROC-AUC 0.699 · Brier Score 0.173

Hinweis: *Reine Geometrie, kein Schusstyp, keine Gegnerpositionen*

Model 02 — Erweitertes Modell ★

Features: Distanz zum Tor · Schusswinkel · Torwart im Sichtdreieck · Distanz nächster Gegner · Anteil blockiertes Tor (Physik. Projektion) · Kopfball (ja/nein)

Ergebnis: ROC-AUC 0.767 · Brier Score 0.151

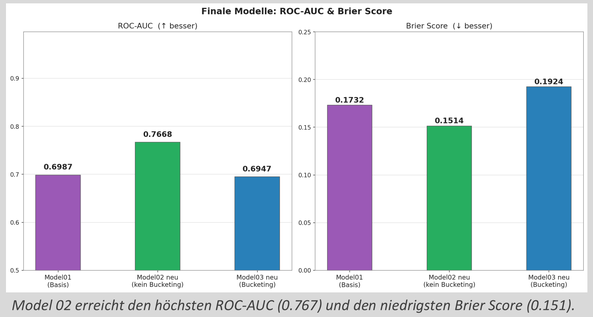
Hinweis: *Kein Koordinaten-Bucketing. Schusstyp und Gegnerdruck physikalisch modelliert.*

Model 03 — Bucketing

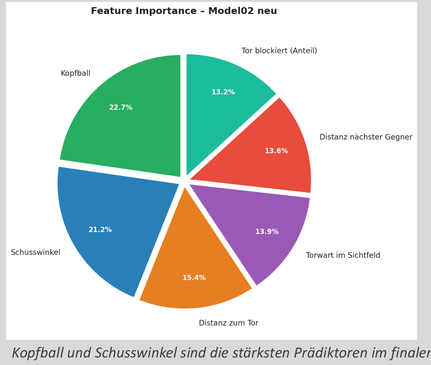
Features: Identisch zu Model 02, zusätzlich Koordinaten auf 1×1 m-Rasterzellen eingerastet (105×68 Grid)

Ergebnis: ROC-AUC 0.695 · Brier Score 0.192

Hinweis: *Bucketing verschlechtert die Generalisierung trotz feinerer Positionsauflösung.*



Model 02 erreicht den höchsten ROC-AUC (0.767) und den niedrigsten Brier Score (0.151).



Kopfball und Schusswinkel sind die stärksten Prädiktoren im finalen Modell.

Methodik

1) DFL-XML mit **kloppy** einlesen; Schüsse extrahieren.
2) Spielrichtung standardisieren (Spiegelung auf das rechte Tor).
3) Feature Engineering aus Schussgeometrie und Tracking.
4) Daten 80/20 stratifiziert splitten, Baseline (DummyClassifier).
5) **XGBoost** trainieren, Hyperparameter (learning_rate, max_depth) per LogLoss tunen, optional Klassengewichtung gegen das Tor-/Kein-Tor-Ungleichgewicht.
6) Bewertung über Accuracy, Precision, Recall und ROC-AUC.

Tools

Python, pandas, NumPy, **kloppy** (DFL/Sportec-Loader), scikit-learn, XGBoost, mplsoccer & matplotlib, eigene xG-GUI (Tkinter/Matplotlib)

Fazit, Grenzen & Ausblick

Ergebnis

Model 02: **ROC-AUC 0,767 · Brier 0,151** – allein aus Geometrie- und Positionsmerkmalen (+9,7 % ggü. Basis). **Stärkste Treiber**: physikalisch berechneter blockierter Toranteil und Kopfball-Erkennung; kontinuierliche Positionen schlagen Koordinaten-Bucketing.

Grenzen

Schmale Datenbasis begünstigt **Scheinkorrelationen** – z. B. erhöhen Gegner im Schussdreieck den xG-Wert, statt ihn zu senken. Es fehlen situative Merkmale (Konter, Standard, Flanke, Abpraller) und individuelle Spielerqualität.

Ausblick

(1) Mehr Trainingsdaten aus mehreren Saisons
(2) situative Features (Profi-Modelle Opta/StatsBomb erreichen ~0,83–0,85 AUC);
(3) bessere Gegnerdruck-Modellierung – nur Verteidiger zwischen Ball und Tor.